Resolução: Eliminação de Variáveis

Unidade Curricular: Representação do Conhecimento e Raciocínio (INF13262M)

1. Resumo da Rede Bayesiana

A rede bayesiana modela os fatores que influenciam a fadiga, o alerta e a concentração:

- **E (Exercise):** {frequent, infrequent}
- **D (Diet):** {healthy, unhealthy}
- **S (Sleep quality):** {good, bad} | Depende de (E, D)
- **F (Fatigue):** {low, high} | Depende de S
- **A (Alertness):** {alert, not alert} | Depende de F
- **C (Concentration):** {concentrated, not concentrated} | Depende de F

2. Pergunta (a): Cálculo de P(D = healthy | F = low)

> **Passo 1: Poda da Rede (Pruning)**
> Como a evidência é **F = low** e a consulta é sobre **D**, as variáveis descendentes de F (**A** e **C**) não contêm informação relevante para calcular a probabilidade a montante. Por isso, as variáveis **A** e **C** são **podadas**.

Passo 2: Formulação da Junta Marginal

Queremos calcular $P(D \mid F = low) = \alpha \sum_{E,S} P(D)\, P(E)\, P(S \mid E, D)\, P(F = low \mid S)$

Passo 3: Eliminação de E

Criamos o fator $f_1(D, S) = \sum_E P(E)\, P(S \mid E, D)$:

Diet (D)	Sleep (S)	Cálculo: P(frequent) × P(S|freq,D) + P(infreq) × P(S|infreq,D)	$f_1(D, S)$
healthy	good	0.40 × 0.85 + 0.60 × 0.60 = 0.34 + 0.36	**0.70**
healthy	bad	0.40 × 0.15 + 0.60 × 0.40 = 0.06 + 0.24	**0.30**
unhealthy	good	0.40 × 0.65 + 0.60 × 0.30 = 0.26 + 0.18	**0.44**
unhealthy	bad	0.40 × 0.35 + 0.60 × 0.70 = 0.14 + 0.42	**0.56**

Passo 4: Eliminação de S e Incorporação da Evidência F = low

Multiplicamos por $P(F = low \mid S)$, onde $P(F{=}low \mid S{=}good) = 0.80$ e $P(F{=}low \mid S{=}bad) = 0.25$:

$$f_2(D) = \sum_S f_1(D, S)\, P(F = low \mid S)$$

- **D = healthy:** $0.70 \times 0.80 + 0.30 \times 0.25 = 0.56 + 0.075 = 0.635$
- **D = unhealthy:** $0.44 \times 0.80 + 0.56 \times 0.25 = 0.352 + 0.14 = 0.492$

Passo 5: Incorporar P(D) e Normalizar (α)

Multiplicamos pelo fator $P(D)$ onde $P(healthy) = 0.35$ e $P(unhealthy) = 0.65$:

- **P'(healthy, F=low)** = $0.35 \times 0.635 = 0.22225$
- **P'(unhealthy, F=low)** = $0.65 \times 0.492 = 0.31980$

Soma total para a constante de normalização α: $0.22225 + 0.31980 = 0.54205$

> **Resultado Final (a):**
> **P(D = healthy | F = low)** = 0.22225 / 0.54205 ≈ **0.4100 (41.00%)**
> **P(D = unhealthy | F = low)** = 0.31980 / 0.54205 ≈ **0.5900 (59.00%)**

3. Pergunta (b): Cálculo de P(E = frequent | A = alert)

Queremos calcular a probabilidade condicional de exercício frequente dado que a pessoa está alerta, eliminando as variáveis na ordem específica: **C, D, S, F**.

Passo a Passo dos Fatores Intermédios:

1. Eliminar C:

Fator envolvido: $P(C \mid F)$. Como C é um nó folha sem evidência nem descendentes na consulta, somar em C produz um fator constante 1.

- **Fator criado:** $f_1(F) = \sum_C P(C \mid F) = 1$
- **Escopo:** (F) — Tamanho: 2 entradas (ambas iguais a 1).

2. Eliminar D:

Fatores envolvidos: $P(D)$ e $P(S \mid E, D)$.

- **Operação:** $f_2(E, S) = \sum_D P(D)\, P(S \mid E, D)$
- **Escopo:** (E, S) — Tamanho: 4 entradas (2 valores de E × 2 valores de S).

Exercise (E)	Sleep (S)	Cálculo: P(healthy) × P(S|E,healthy) + P(unhealthy) × P(S|E,unhealthy)	$f_2(E, S)$
frequent	good	0.35 × 0.85 + 0.65 × 0.65 = 0.2975 + 0.4225	**0.7200**
frequent	bad	0.35 × 0.15 + 0.65 × 0.35 = 0.0525 + 0.2275	**0.2800**
infrequent	good	0.35 × 0.60 + 0.65 × 0.30 = 0.2100 + 0.1950	**0.4050**
infrequent	bad	0.35 × 0.40 + 0.65 × 0.70 = 0.1400 + 0.4550	**0.5950**

3. Eliminar S:

Fatores envolvidos: $f_2(E, S)$ e $P(F \mid S)$.

- **Operação:** $f_3(E, F) = \sum_S f_2(E, S)\, P(F \mid S)$
- **Escopo:** (E, F) — Tamanho: 4 entradas.

Exercise (E)	Fatigue (F)	Cálculo: f_2(E,good) × P(F|good) + f_2(E,bad) × P(F|bad)	$f_3(E, F)$
frequent	low	0.7200 × 0.80 + 0.2800 × 0.25 = 0.5760 + 0.0700	**0.6460**
frequent	high	0.7200 × 0.20 + 0.2800 × 0.75 = 0.1440 + 0.2100	**0.3540**
infrequent	low	0.4050 × 0.80 + 0.5950 × 0.25 = 0.3240 + 0.14875	**0.47275**
infrequent	high	0.4050 × 0.20 + 0.5950 × 0.75 = 0.0810 + 0.44625	**0.52725**

4. Eliminar F:

Fatores envolvidos: $f_3(E, F)$ e $P(A = alert \mid F)$ (onde P(alert|low) = 0.90 e P(alert|high) = 0.30).

- **Operação:** $f_4(E) = \sum_F f_3(E, F)\, P(A = alert \mid F)$
- **E = frequent:** $0.6460 \times 0.90 + 0.3540 \times 0.30 = 0.5814 + 0.1062 = 0.6876$
- **E = infrequent:** $0.47275 \times 0.90 + 0.52725 \times 0.30 = 0.425475 + 0.158175 = 0.58365$

5. Incorporar P(E) e Normalizar:

- **P'(frequent, alert):** $P(E=frequent) \times f_4(frequent) = 0.40 \times 0.6876 = 0.27504$
- **P'(infrequent, alert):** $P(E=infrequent) \times f_4(infrequent) = 0.60 \times 0.58365 = 0.35019$

Soma total: $0.27504 + 0.35019 = 0.62523$

> **Resultado Final (b):**
> **P(E = frequent | A = alert)** = 0.27504 / 0.62523 ≈ **0.4399 (43.99%)**

Perguntas Qualitativas da Alínea (b):

- **Qual é o maior fator criado?**
  O maior fator criado durante o processo tem **4 entradas** (os fatores intermédios com escopos de duas variáveis binárias: (E, S) e (E, F)). Na fase de junção antes da soma, o maior escopo atinge 3 variáveis (E, D, S com 8 entradas).
- **Como mudaria se S fosse eliminado antes de D?**
  Se eliminássemos **S** antes de **D**, teríamos de combinar primeiro $P(S \mid E, D)$ com $P(F \mid S)$. Ao somar em S, criaríamos um fator com escopo **(E, D, F)** com **8 entradas** antes de eliminar D. Ou seja, eliminar S antes aumenta a dimensão dos fatores intermédios e a complexidade computacional.